

IMDB Movie Recommender

System rekomendacji filmów oparty na content-based filtering

Dokumentacja projektu końcowego SUML

Autorzy: Damian Ruczyński, Borys Piwoński, Martyna Głowacka

Uczelnia: Polsko-Japońska Akademia Technik Komputerowych

Data: 24 czerwca 2026

Repozytorium: https://github.com/DamianRuczi/imdbL_suml_project

Streszczenie

Projekt dotyczy stworzenia systemu rekomendacji filmów na podstawie danych IMDB. Aplikacja dla podanego tytułu filmu zwraca listę podobnych produkcji, wykorzystując informacje takie jak gatunki, reżyserzy, obsada oraz opis filmu. System działa w podejściu content-based filtering, dlatego nie wymaga historii ocen ani aktywności użytkownika.

Rozwiązanie składa się z backendu FastAPI, który udostępnia endpointy API, oraz frontendu Streamlit, który umożliwia wygodne wyszukiwanie rekomendacji przez interfejs webowy. Model rekomendacyjny wykorzystuje reprezentację TF-IDF oraz podobieństwo cosinusowe.

1. Cel i opis problemu

Celem projektu jest przygotowanie aplikacji, która pomaga użytkownikowi znaleźć filmy podobne do wybranego tytułu. Problem został rozwiązany jako zadanie rekomendacyjne typu content-based filtering, czyli rekomendacje są generowane na podstawie cech samych filmów, a nie na podstawie historii użytkowników.

Takie podejście sprawdza się szczególnie wtedy, gdy nie dysponujemy danymi o ocenach użytkowników albo chcemy rekomendować filmy wyłącznie na podstawie ich treści i metadanych.

2. Dane


Projekt wykorzystuje zbiór danych filmowych IMDB zapisany w pliku `final_dataset.parquet`. Dane po przetworzeniu zawierają m.in. tytuł filmu, rok produkcji, ocenę, gatunki, reżyserów, obsadę oraz opis.

W etapie preprocessingu dane są czyszczone, normalizowane oraz ograniczane do kolumn potrzebnych do trenowania rekomendatora. Z danych usuwane są rekordy z brakami w wymaganych polach, duplikaty oraz wartości spoza przyjętych zakresów.

3. Architektura system

System składa się z kilku warstw:

- warstwa danych i preprocessingu,
- model rekomendacyjny,
- backend FastAPI,
- frontend Streamlit,
- konteneryzacja Docker.



Rys. 1. Architektura rozwiązania.

Backend FastAPI odpowiada za udostępnienie endpointów `/health`, `/movies` oraz `/recommend`. Frontend Streamlit komunikuje się z backendem przez zapytania HTTP i prezentuje wyniki użytkownikowi w formie listy rekomendacji.

4. Model rekomendacyjny

Model został zbudowany jako rekomendator content-based. Dla każdego filmu tworzony jest tekstowy opis łączący wybrane pola: gatunki, reżyserów, obsadę oraz opis filmu. Pola te mają różne wagi — gatunki są powtarzane najwięcej razy, następnie reżyserzy, obsada i opis.

Wagi pól wykorzystywanych w reprezentacji tekstowej filmu:

Pole	Waga
genres	x4
directors	x3
stars	x2
description	x1

Tak przygotowany tekst jest przekształcany do reprezentacji TF-IDF. Następnie podobieństwo między filmami obliczane jest za pomocą cosine similarity. Dla podanego tytułu aplikacja wybiera filmy najbardziej podobne do filmu bazowego.

5. Trening modelu

Trening modelu odbywa się w skrypcie `model/train.py`. Skrypt sprawdza, czy istnieją przetworzone dane, a jeśli nie — uruchamia preprocessing. Następnie wczytuje dane, trenuje rekomendator i zapisuje artefakt modelu do pliku `model/artifacts/recommender.pkl`.

Ze względu na charakter projektu nie zastosowano klasycznych metryk klasyfikacyjnych, takich jak accuracy, F1 czy ROC-AUC. Model rekomendacyjny oceniany jest jakościowo przez analizę zwracanych rekomendacji oraz wartości podobieństwa cosine similarity.

Najważniejsze ustawienia treningu rekomendatora:

Element	Wartość
Reprezentacja tekstu	TF-IDF
Miara podobieństwa	cosine similarity
Maksymalna liczba cech	25 000
N-gramy	1-2
Model	Content-based recommender

Po treningu wykonywany jest również test rekomendacji dla przykładowego filmu, co pozwala szybko sprawdzić, czy model działa poprawnie.

```
Trenuję ContentRecommender...
Trening zakończony w 9.0 s

Test rekomendacji dla 'Inception':
title year genres rating score
The Dark Knight Rises 2012 Action Epic, Epic, Superhero, Action, Drama, Thriller 8.4 0.4038
War for the Planet of the Apes 2017 Action Epic, Adventure Epic, Dystopian Sci-Fi, Epic, Sci-Fi Epic, Action, Adventure, Drama, Sci-Fi, Thriller 7.4 0.3127
Batman Begins 2005 Action Epic, Epic, Superhero, Tragedy, Action, Drama 8.2 0.3028
Athena 2022 Action Epic, Epic, Psychological Thriller, Action, Drama, Thriller 6.8 0.2884
Dunkirk 2017 Action Epic, Epic, Historical Epic, Period Drama, War Epic, Action, Drama, History, Thriller, War 7.8 0.2851

Model zapisany: C:\Users\marty\PycharmProjects\imdbL_suml_project\model\artifacts\recommender.pkl (22.9 MB)
Model zapisany
```

Rys. 2. Wynik treningu modelu oraz test rekomendacji dla filmu „Inception”.

6. Serwowanie modelu przez FastAPI

Backend FastAPI udostępnia endpointy:

Endpoint	Metoda	Opis
/health	GET	Sprawdzenie statusu aplikacji
/movies	GET	Lista dostępnych filmów
/recommend	POST	Rekomendacje dla podanego tytułu
/docs	GET	Dokumentacja Swagger

Endpoint `/recommend` przyjmuje tytuł filmu, opcjonalny rok oraz limit liczby rekomendacji. W odpowiedzi zwracana jest lista podobnych filmów wraz z rokiem, gatunkami, oceną IMDB oraz wynikiem podobieństwa.

Request dla `/recommend`:

```
{
  "title": "Inception",
  "year": 2010,
  "limit": 5
}
```

Pole `year` jest opcjonalne. Jeśli zostanie podane, system zawęży rekomendacje do filmów zbliżonych czasowo. Pole `limit` określa maksymalną liczbę rekomendacji.

Response dla /recommend:

```
{
  "count": 5,
  "results": [
    {
      "title": "The Dark Knight Rises",
      "year": 2012,
      "genres": "Action Epic, Epic, Superhero, Action, Drama, Thriller",
      "rating": 8.4,
      "score": 0.4038
    },
    {
      "title": "War for the Planet of the Apes",
      "year": 2017,
      "genres": "Action Epic, Adventure Epic, Dystopian Sci-Fi, Epic, Sci-Fi Epic, Action, Adventure, Drama, Sci-Fi, Thriller",
      "rating": 7.4,
      "score": 0.3127
    },
    {
      "title": "Batman Begins",
      "year": 2005,
      "genres": "Action Epic, Epic, Superhero, Tragedy, Action, Drama",
      "rating": 8.2,
      "score": 0.3028
    },
    {
      "title": "Athena",
      "year": 2022,
      "genres": "Action Epic, Epic, Psychological Thriller, Action, Drama, Thriller",
      "rating": 6.8,
      "score": 0.2884
    },
    {
      "title": "Dunkirk",
      "year": 2017,
      "genres": "Action Epic, Epic, Historical Epic, Period Drama, War Epic, Action, Drama, History, Thriller, War",
      "rating": 7.8,
      "score": 0.2851
    }
  ]
}
```

Pole `count` oznacza liczbę zwróconych rekomendacji, a `results` zawiera listę filmów podobnych do tytułu wejściowego. Pole `score` określa wartość podobieństwa obliczoną na podstawie cosine similarity - im wyższa wartość, tym większe podobieństwo filmu do zapytania.

7. Frontend Streamlit

Frontend został przygotowany w Streamlit. Użytkownik może wpisać tytuł filmu, opcjonalnie podać rok oraz wybrać liczbę rekomendacji. Aplikacja wysyła zapytanie do backendu FastAPI i prezentuje wyniki w czytelnej formie.

IMDB Movie Recommender

System rekomendacji filmów content-based

Tytuł filmu

Inception

Rok (opcjonalnie)

0

– +

Liczba rekomendacji

5

Szukaj rekomendacji

Top 5 rekomendacji dla „Inception”

The Dark Knight Rises (2012) Action Epic, Epic, Superhero, Action, Drama, Thriller	Ocena IMDB 8.4	Podobierństwo 0.40
War for the Planet of the Apes (2017) Action Epic, Adventure Epic, Dystopian Sci-Fi, Epic, Sci-Fi Epic, Action, Adventure, Drama, Sci-Fi, Thriller	Ocena IMDB 7.4	Podobierństwo 0.31
Batman Begins (2005) Action Epic, Epic, Superhero, Tragedy, Action, Drama	Ocena IMDB 8.2	Podobierństwo 0.30
Athena (2022) Action Epic, Epic, Psychological Thriller, Action, Drama, Thriller	Ocena IMDB 6.8	Podobierństwo 0.29
Dunkirk (2017) Action Epic, Epic, Historical Epic, Period Drama, War Epic, Action, Drama, History, Thriller, War	Ocena IMDB 7.8	Podobierństwo 0.29

Rys. 3. Interfejs aplikacji Streamlit z wynikami rekomendacji dla filmu „Inception”.

Dodatkowo frontend pozwala wyświetlić listę wszystkich filmów dostępnych w bazie.

▼ Lista wszystkich filmów w bazie

title	year
The Mystery of Thug Island	1966
Love at Twenty	1963
Bye Bye Braverman	1968
The Children of Huang Shi	2008
Killer Whale	1962
Mirando Al Cielo	2023
West and Soda	1966
Support the Girls	2018
The Big City	1963
Dopamine	2003

Rys. 4.

8. Konteneryzacja

Projekt może być uruchamiany lokalnie albo za pomocą Dockera. Konteneryzacja pozwala uruchomić aplikację w powtarzalnym środowisku bez ręcznej konfiguracji zależności.

Aplikację można uruchomić poleceniem:

```
docker-compose up --build
```

9. Sposób uruchomienia

Uruchomienie lokalne

```
python -m venv .venv
pip install -r requirements.txt
python model/train.py
uvicorn app.main:app --reload --port 8008
streamlit run app/streamlit_app.py
```

Uruchomienie przez Docker

```
docker-compose up --build
```

API dostępne jest pod adresem:

<http://localhost:8008/docs>

Frontend Streamlit dostępny jest pod adresem:

<http://localhost:8501>

10. Podsumowanie

Projekt realizuje kompletny system rekomendacji filmów, od przetwarzania danych, przez trening modelu, aż po udostępnienie wyników w aplikacji webowej. Zastosowane podejście content-based filtering umożliwia generowanie rekomendacji bez potrzeby posiadania danych o użytkownikach, co upraszcza wdrożenie i pozwala skupić się na cechach samych filmów.

